

Análisis predictivo de la rentabilidad de los microestablecimientos en Bogotá mediante modelos estadísticos y de aprendizaje automático

Lubin Fernando Abaunza Melo

14 de diciembre de 2025

Resumen

La estabilidad económica y la rentabilidad de los microestablecimientos constituyen un pilar central de la dinámica productiva urbana de Bogotá. No obstante, su análisis empírico enfrenta desafíos significativos derivados de una marcada heterogeneidad, la presencia de valores atípicos y relaciones no lineales entre las variables económicas y sociales que los caracterizan.

Este estudio examina los factores que influyen en la rentabilidad de los microestablecimientos de la ciudad, a partir de datos de la Encuesta de Microestablecimientos (MICRO-2016) realizada por el DANE. La investigación adopta un enfoque aplicado que integra estadística descriptiva, análisis de asociación y técnicas de modelación predictiva.

Se emplean diversas estrategias de modelación, entre ellas modelos lineales regularizados (Ridge y LASO), regresión robusta (LAD) y algoritmos de aprendizaje automático basados en boosting (XGBoost y CatBoost). El desempeño de los modelos se evalúa mediante validación fuera de muestra, utilizando métricas como el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el coeficiente de determinación predictivo (R^2). Adicionalmente, para los modelos de aprendizaje automático, se aplican técnicas de interpretabilidad basadas en valores SHAP (SHapley Additive exPlanations), las cuales permiten identificar y cuantificar la contribución marginal de cada covariable a la rentabilidad, tanto a nivel global como individual.

Los resultados indican que, en un contexto caracterizado por alta variabilidad y observaciones influyentes, los modelos regularizados y robustos pueden alcanzar un desempeño predictivo comparable al de enfoques más complejos. Asimismo, variables relacionadas con la formalización, la antigüedad del negocio y las características productivas emergen como factores clave para explicar la rentabilidad de los microestablecimientos en Bogotá.

Abstract

Economic stability and the profitability of microenterprises constitute a central pillar of Bogotá's urban productive dynamics. Nevertheless, their empirical analysis faces significant challenges arising from marked heterogeneity, the presence of outliers, and non-linear relationships among the economic and social variables that characterize them.

This study examines the factors influencing the profitability of microenterprises in the city, drawing on data from the Microenterprise Survey (MICRO-2016) conducted by DANE. The research adopts an applied approach that integrates descriptive statistics, association analysis, and predictive modeling techniques.

Several modeling strategies are employed, including regularized linear models (Ridge and LASSO), robust regression (LAD), and machine learning algorithms using boosting (XGBoost and CatBoost). Model performance is assessed through out-of-sample validation, using metrics such as the root mean squared error (RMSE), mean absolute error (MAE), and predictive coefficient of determination (R^2). Furthermore, for the machine learning models, interpretability techniques based on SHAP values (SHapley Additive exPlanations) are applied, enabling the identification and quantification of the marginal contribution of each covariate to profitability, both at the global and individual levels.

The findings indicate that, in a context marked by high variability and influential observations, regularized and robust models can achieve predictive performance comparable to that of more complex approaches. In addition, variables related to formalization, business longevity, and productive characteristics emerge as key factors in explaining the profitability of Bogotá’s microenterprises.

Palabras clave: microestablecimientos; rentabilidad; modelos predictivos; regularización; interpretabilidad (SHAP).

Introducción

Los microestablecimientos constituyen un componente esencial del tejido productivo urbano, particularmente en ciudades como Bogotá, donde representan una fuente significativa de empleo, generación de ingresos y dinamización de la economía local. Estas unidades económicas, caracterizadas por su reducido tamaño, limitada capacidad financiera y marcadas diferencias, enfrentan múltiples desafíos vinculados con la estabilidad económica, la rentabilidad y la sostenibilidad en el tiempo. Factores como la formalización, la antigüedad del negocio, las características del propietario y las condiciones del entorno económico inciden de manera decisiva en su desempeño financiero.

El análisis de los factores asociados al desempeño económico y la rentabilidad de los microestablecimientos adquiere especial relevancia en contextos urbanos, donde la competencia, los costos operativos y la informalidad suelen ser elevados. Comprender qué variables se relacionan con un mejor desempeño económico no solo permite caracterizar la situación actual de estos negocios, sino que también aporta evidencia valiosa para el diseño de políticas públicas, programas de apoyo y estrategias de fortalecimiento empresarial dirigidas a este sector.

Desde una perspectiva metodológica, el análisis del desempeño económico de los microestablecimientos presenta diversos desafíos. En particular, las relaciones entre las variables explicativas y la rentabilidad pueden ser complejas y no necesariamente lineales. En este contexto, resulta pertinente combinar enfoques de regularización con técnicas de aprendizaje automático, con el fin de mejorar la capacidad predictiva de los modelos y, al mismo tiempo, facilitar una interpretación más detallada de los factores asociados al desempeño económico. Este trabajo adopta un enfoque aplicado, utilizando información proveniente de microestablecimientos ubicados en Bogotá. Se emplean y comparan distintos modelos estadísticos y de aprendizaje automático, entre ellos regresiones regularizadas (LASSO y Ridge), modelos de boosting (XGBoost y CatBoost) y métodos resistentes (LAD). Asimismo, se incorporan herramientas de interpretabilidad como los valores SHAP, con el propósito de identificar y analizar las variables que más contribuyen al desempeño predictivo de los modelos complejos.

El objetivo general del estudio es analizar los factores que determinan la estabilidad económica y la rentabilidad de los microestablecimientos en Bogotá. De manera específica, se busca: (i) describir las principales características económicas y sociales de los microestablecimientos analizados; (ii) identificar las variables que influyen en la rentabilidad y sostenibilidad de estos negocios; y (iii) explorar la relación entre la formalización, la antigüedad y el desempeño económico. En conjunto, este trabajo pretende aportar evidencia empírica y metodológica que contribuya a una comprensión más precisa del comportamiento económico de los microestablecimientos urbanos.

Marco teórico.

La literatura sobre microestablecimientos y pequeñas unidades productivas destaca su papel central en la estructura económica urbana y su contribución al empleo y a la generación de ingresos. En el contexto colombiano, estos negocios suelen caracterizarse por operar con bajos niveles de capital, alta vulnerabilidad frente a choques económicos y una fuerte dependencia de las decisiones del propietario. Rodríguez Lesmes (2020) documenta que los microestablecimientos presentan una marcada heterogeneidad en términos de productividad, formalización y desempeño económico, lo que sugiere que su rentabilidad está estrechamente asociada a factores estructurales y de gestión.

Desde una perspectiva más aplicada, diversos estudios de caso han analizado los factores que inciden en la sostenibilidad financiera de las pequeñas y microempresas. Bravo Moreno (2013) señala que aspectos administrativos y financieros, como la planeación, el control de costos y el acceso a financiamiento, juegan un papel determinante en el éxito o fracaso de estas unidades productivas. De manera similar, Cifuentes Idárraga (2024) encuentra que la sostenibilidad financiera de las PYMES está relacionada con la capacidad de adaptación del negocio, la formalización y la adecuada gestión de los recursos, resaltando la importancia de analizar estos factores de forma conjunta para comprender el desempeño económico de los microestablecimientos

Metodología

Este estudio adopta un enfoque aplicado, sustentado en el análisis empírico de información proveniente de la Encuesta de Microestablecimientos del DANE [1], restringida a los negocios ubicados en Bogotá. El objetivo metodológico es analizar los factores asociados al desempeño económico de estas unidades, combinando análisis descriptivo, modelos predictivos y herramientas de interpretabilidad.

Preparación y tratamiento de los datos

En una primera etapa, se cargó y revisó la base de datos que se encuentra abierta al público en la página del DANE. Luego se identificó la variable de interés que corresponde a los ingresos anuales del microestablecimiento, y el conjunto de covariables disponibles. Las variables se clasificaron en numéricas y categóricas, según su naturaleza.

Para las variables categóricas, se aplicó un tratamiento diferenciado de los valores faltantes. Se distinguieron aquellos de carácter estructural, es decir, los que surgen porque la pregunta no aplica a ciertos establecimientos (por ejemplo, razones de uso de internet en negocios sin conexión). En estos casos, los valores faltantes se recodificaron explícitamente como la categoría “No aplica”. En contraste, no se realizó una imputación generalizada, evitando introducir categorías artificiales en variables cuya ausencia de información carecía de interpretación estructural clara.

Posteriormente, las variables categóricas se transformaron en factores, lo que permitió su adecuada incorporación en los distintos modelos utilizados.

Análisis descriptivo y exploratorio

Se efectuó un análisis descriptivo inicial de la variable de ingresos, incluyendo estadísticas resumen, cuantiles, histogramas y diagramas de caja, con el fin de caracterizar su distribución y magnitud.

De manera complementaria, se exploraron las covariables. Para las variables numéricas se calcularon coeficientes de asociación (Pearson, Spearman, Kendall y Xi), mientras que para las categóricas se aplicaron pruebas no paramétricas de Kruskal–Wallis, con el objetivo de identificar relaciones relevantes con el desempeño económico del microestablecimiento.

Partición de la muestra y construcción de matrices de diseño

La base de datos se dividió en una muestra de entrenamiento (80 %) y una de prueba (20 %), mediante partición estratificada sobre la variable de ingresos, asegurando una distribución comparable entre ambas.

En los modelos que lo requerían, se construyeron matrices de diseño mediante variables indicadoras (dummies) derivadas de las covariables categóricas. Se utilizaron matrices dispersas (sparse matrices), lo que permitió un manejo eficiente de un gran número de predictores generados por la expansión categórica.

Selección de variables mediante regresión forward

Para la construcción del modelo de regresión lineal se utilizó el método de selección progresiva de variables (*forward selection*) dada la gran cantidad de variables explicativas que se tiene. La selección se basó en la minimización del criterio de información de Akaike (AIC), lo cual permite balancear la calidad del ajuste del modelo con su complejidad.

Modelos de aprendizaje automático: XGBoost y CatBoost

Como parte central del análisis predictivo, se estimaron modelos de regresión basados en árboles de decisión mediante XGBoost y CatBoost. En XGBoost, se implementó un proceso sistemático de búsqueda aleatoria de hiperparámetros, evaluando combinaciones relacionadas con la profundidad de los árboles, la tasa de aprendizaje, la regularización y los esquemas de submuestreo. Cada configuración se evaluó mediante validación cruzada repetida, utilizando el RMSE como métrica principal. Se incorporó además un mecanismo de early stopping para prevenir el sobreajuste. El número óptimo de iteraciones se determinó a partir de un procedimiento adicional de validación cruzada, tras lo cual se entrenó el modelo final exclusivamente sobre la muestra de entrenamiento.

CatBoost se ajustó aprovechando su capacidad nativa para manejar variables categóricas sin necesidad de codificación en dummies. Se realizó una búsqueda iterativa de hiperparámetros, variando la profundidad del árbol, la tasa de aprendizaje y los términos de regularización. El desempeño se evaluó mediante validación cruzada, seleccionando el número óptimo de iteraciones en función del mínimo RMSE observado. Posteriormente, se entrenó el modelo final sobre la muestra de entrenamiento con los hiperparámetros seleccionados.

Modelos de regularización y regresión resistente

Como referencia comparativa, se estimaron modelos de regresión penalizada LASSO y Ridge, utilizando validación cruzada para seleccionar el parámetro de penalización óptimo. El modelo LASSO se empleó como herramienta de selección de variables, identificando un subconjunto reducido de covariables relevantes.

A partir de estas variables, se estimó un modelo de regresión resistente LAD (Least Absolute Deviations), centrado en la mediana condicional de los ingresos. Previo al ajuste, se eliminaron covariables altamente correlacionadas para evitar colinealidad y asegurar estabilidad numérica en la estimación.

Evaluación del desempeño e interpretabilidad

El desempeño predictivo de todos los modelos se evaluó sobre la muestra de prueba, utilizando métricas estándar como RMSE, MAE y el coeficiente de determinación predictivo (R^2).

Finalmente, en los modelos basados en árboles se incorporaron herramientas de interpretabilidad mediante valores SHAP, que permiten cuantificar la contribución individual de cada covariable a las predicciones. Este análisis facilitó una interpretación más clara de los factores asociados al desempeño económico de los microestablecimientos.

Resultados

Análisis descriptivo

La variable de interés del estudio es el ingreso anual del microestablecimiento, medido a partir de la contabilidad de ingresos reportada. La Figura 1 presenta la distribución empírica del ingreso anual mediante un histograma, junto con un diagrama de caja que resume su comportamiento central y dispersión.




Figura 1: Distribución y boxplot del ingreso anual de los microestablecimientos

Como se observa en la Figura 1, la distribución del ingreso anual es sesgada a la derecha, con una alta concentración de microestablecimientos en niveles bajos y medios de ingreso y una cola larga asociada a establecimientos con ingresos considerablemente más altos. El diagrama de caja evidencia la presencia de valores extremos superiores, lo cual es consistente con la heterogeneidad característica de este tipo de unidades productivas.

La Tabla 1 resume las principales estadísticas descriptivas del ingreso anual. El ingreso mediano se sitúa en torno a los 60 millones de pesos, mientras que el ingreso promedio es superior, reflejando la influencia de los valores altos en la cola derecha de la distribución.

Tabla 1: Estadísticas descriptivas del ingreso anual

Estadístico	Valor
Mínimo	14,000,000
Primer cuartil (Q1)	35,000,000
Mediana	60,000,000
Media	76,637,974
Tercer cuartil (Q3)	100,000,000
Máximo	244,000,000

Estos resultados confirman la elevada dispersión del ingreso anual entre microestablecimientos y refuerzan la necesidad de emplear metodologías flexibles que permitan capturar relaciones no lineales y comportamientos heterogéneos en etapas posteriores del análisis.

■ Asociación entre covariables numéricas e ingreso anual

Con el fin de explorar la relación entre el ingreso anual y las covariables cuantitativas, se calcularon distintos coeficientes de asociación, incluyendo correlaciones de Pearson, Spearman, Kendall y el coeficiente ξ de Chatterjee. La Figura 2 presenta una comparación gráfica de estos coeficientes para las principales variables numéricas.




Figura 2: Comparación de coeficientes de correlación entre covariables numéricas e ingreso anual

La Figura 2 muestra que variables asociadas a los costos operativos y al tamaño del establecimiento, como el gasto en mercancía vendida, el número de trabajadores y los pagos por salarios, presentan las mayores asociaciones positivas con el ingreso anual. En contraste, otras variables exhiben asociaciones más débiles o cercanas a cero, lo que sugiere relaciones menos directas o potencialmente no lineales.

La Tabla 2 presenta los coeficientes de correlación ordenados según la magnitud del coeficiente de Pearson.

Tabla 2: Coeficientes de correlación entre covariables numéricas e ingreso anual

Variable	Pearson	Spearman	Kendall	ξ
Gasto en mercancía vendida	0.755	0.730	0.566	0.395
Personas con sueldo o salario	0.415	0.420	0.325	0.130
Pago de sueldos y salarios	0.413	0.431	0.322	0.143
Número de trabajadores	0.364	0.362	0.280	0.108
Gasto en arrendamiento	0.346	0.320	0.236	0.096
⋮	⋮	⋮	⋮	⋮

En general, los resultados sugieren que el ingreso anual está estrechamente vinculado con variables relacionadas con la escala productiva y los costos operativos, mientras que otras covariables presentan asociaciones más débiles, lo cual justifica la inclusión de métodos de selección y modelación más flexibles en el análisis posterior.

■ Asociación entre covariables categóricas e ingreso anual

Para las variables categóricas, se emplearon pruebas no paramétricas de Kruskal–Wallis con el fin de evaluar si la distribución del ingreso anual difiere significativamente entre categorías. La Tabla 3 resume los valores p obtenidos para cada covariable.

Tabla 3: Pruebas de Kruskal–Wallis entre covariables categóricas e ingreso anual

Variable	Valor p
Lleva contabilidad	$3,5 \times 10^{-161}$
Naturaleza del registro	$3,6 \times 10^{-87}$
Registro renovado	$5,7 \times 10^{-72}$
Velocidad de conexión a internet	$4,4 \times 10^{-66}$
Registro en Cámara de Comercio	$3,8 \times 10^{-60}$
Tipo de conexión a internet	$1,4 \times 10^{-45}$
Tiene servicio de internet	$3,1 \times 10^{-45}$
Tiene RUT	$1,2 \times 10^{-37}$
Tiempo de funcionamiento	$1,4 \times 10^{-12}$
Sector económico	$5,3 \times 10^{-6}$
Solicitud de préstamo último año	$2,9 \times 10^{-2}$
Préstamo aprobado	$8,4 \times 10^{-2}$

Los resultados evidencian asociaciones estadísticamente significativas entre el ingreso anual y variables relacionadas con la formalización empresarial, la gestión contable y el acceso a tecnologías de la información. Asimismo, la antigüedad del negocio y el sector económico muestran diferencias relevantes en la distribución del ingreso. En contraste, no se encuentra evidencia estadística de asociación para variables vinculadas al resultado específico de la solicitud de crédito, como la aprobación del préstamo.

En conjunto, el análisis descriptivo y de asociación revela una elevada heterogeneidad en el desempeño económico de los microestablecimientos y destaca la importancia de factores estructurales, tecnológicos y de formalización. Estos hallazgos proporcionan una base empírica sólida para la implementación de modelos predictivos y explicativos más complejos en las secciones siguientes.

Comparación del desempeño predictivo de los modelos

Tabla 4: Comparación del desempeño de los modelos ajustados

Modelo	RMSE Test / CV	MAE
Regresión lineal (Forward)	22,389,094	16,856,713
XGBoost	19,975,654	14,320,726
CatBoost	19,849,429	14,606,261
LASSO	22,371,114	17,000,042
RIDGE	23,515,902	18,287,901
LAD	22,804,816	16,086,522

Los resultados presentados en la Tabla 4 muestran que los modelos basados en aprendizaje automático, en particular XGBoost y CatBoost, presentan el mejor desempeño predictivo entre los modelos evaluados, evidenciado por los menores valores de RMSE y MAE en la muestra de prueba. Ambos modelos exhiben un comportamiento muy similar, lo cual sugiere una capacidad comparable para capturar patrones relevantes en los datos.

Este mejor desempeño puede atribuirse a su habilidad para modelar relaciones no lineales e interacciones complejas entre las covariables, así como a un aprovechamiento más eficiente de la información contenida en variables categóricas, especialmente en el caso de CatBoost.

Por su parte, los modelos lineales y regularizados (Regresión lineal con selección forward, LASSO y Ridge) muestran un desempeño competitivo, aunque inferior al de los modelos basados en árboles.

Finalmente, el modelo LAD presenta un desempeño intermedio, destacándose por su menor sensibilidad a valores atípicos, aunque sin superar a los modelos de boosting en términos de precisión predictiva.

Interpretabilidad de los modelos mediante valores SHAP




Figura 3: Importancia SHAP obtenida con el modelo CatBoost

La figura 3 revela las variables que para nuestro conjunto de datos resultaron más relevantes según el modelo que mejor predicciones tuvo sobre el conjunto de prueba. La mayor parte de la importancia es atribuida a la variable que indica el gasto en mercancía vendida al año.




Figura 4: Importancia SHAP obtenida con el modelo XGBoost

Para el XGBoost, la importancia SHAP la obtenemos en la figura 4. Vemos que las 3 variables más importantes coinciden en ambos modelos. De hecho, vemos un cambio notable en la importancia de ambos modelos a partir de la cuarta variable más importante.

De hecho, vemos similitudes en estos resultados con el análisis de correlación realizado anteriormente.

Conclusiones

Los resultados del análisis indican que la variable con mayor relevancia para explicar los ingresos anuales de los microestablecimientos en Bogotá es el gasto de mercancía vendida por año. Esta variable captura de manera directa la escala de operación del establecimiento y, en consecuencia, su capacidad productiva y comercial. En términos económicos, mayores costos asociados a la adquisición de insumos suelen corresponder a mayores volúmenes de producción y venta, lo cual resulta consistente con la teoría económica básica y con la interpretación empírica de los modelos ajustados.

Las siguientes variables en orden de importancia se encuentran asociadas a la inversión en inmuebles y al gasto en personal. Estos resultados, aunque no inesperados, refuerzan la interpretación de que los ingresos anuales están fuertemente vinculados al tamaño operativo y a la estructura productiva del negocio, más que a características aisladas o institucionales.

A partir de este punto, se observa que las variables relevantes difieren entre los dos modelos con mejor desempeño predictivo. No obstante, en ambos casos emergen de manera recurrente variables relacionadas con la formalización del empleo —reflejadas en los pagos a salud, pensión y ARL—, el aprovechamiento de tecnologías de información y comunicación, y los gastos asociados al mantenimiento y operación del establecimiento. En conjunto, estos hallazgos sugieren que la formalización no debe interpretarse únicamente como un cumplimiento normativo, sino también como un componente funcional de la productividad. En este contexto, el empleo formal actúa como un proxy del tamaño, la organización y la capacidad operativa del negocio.

Por otro lado, la antigüedad del establecimiento no figura entre las variables de mayor importancia en los modelos analizados. Este resultado sugiere que la antigüedad estaría siendo explicada indirectamente por otras variables más cercanas a la escala productiva y al nivel de actividad económica. En consecuencia, un mayor tiempo de funcionamiento no garantiza necesariamente mayores ingresos, lo cual pone de manifiesto que la supervivencia en el mercado no implica, por sí sola, crecimiento económico.

A pesar de los aportes del presente estudio, es importante reconocer algunas limitaciones que condicionan el alcance de los resultados obtenidos:

1. **Limitación en las variables observadas:** La ausencia de información sobre crecimiento de ventas, variabilidad de ingresos, nivel educativo del personal, experiencia previa del emprendedor, capacitación recibida y otros factores estratégicos limita la capacidad explicativa del análisis.
2. **Naturaleza observacional y transversal del estudio:** Al tratarse de un análisis basado en un único corte temporal, no es posible inferir dinámicas en el tiempo ni establecer relaciones causales entre las prácticas empresariales y el desempeño económico de los establecimientos.
3. **Sesgo de supervivencia:** La base de datos incluye únicamente microestablecimientos activos, lo cual excluye a aquellos que han salido del mercado y puede sesgar los resultados hacia empresas relativamente más estables.

Superar estas limitaciones permitiría avanzar hacia una comprensión más integral del comportamiento económico de las microempresas en Bogotá y contribuir al diseño de estrategias de intervención con mayor impacto en la economía local. En este sentido, futuras investigaciones podrían beneficiarse del uso de diseños longitudinales, modelos de sobrevivencia, análisis jerárquicos o enfoques basados en grafos causales dirigidos (DAGs), lo cual requeriría una recolección de información más detallada y sistemática.

Referencias

- [1] Departamento Administrativo Nacional de Estadística (DANE). *Encuesta de Microestablecimientos 2016: Base de microdatos y documento metodológico*. Bogotá, Colombia, 2018. Disponible en: <https://microdatos.dane.gov.co/catalog/560>
- [2] Departamento Administrativo Nacional de Estadística (DANE). *Metodología de la Encuesta de Microestablecimientos (MICRO)*. Bogotá, Colombia, 2020.
- [3] T. Chen y C. Guestrin. *XGBoost: A scalable tree boosting system*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785–794, 2016.
- [4] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush y A. Gulin. *CatBoost: Unbiased boosting with categorical features*. Advances in Neural Information Processing Systems, vol. 31, 2018.
- [5] S. M. Lundberg y S.-I. Lee. *A unified approach to interpreting model predictions*. Advances in Neural Information Processing Systems, vol. 30, 2017.
- [6] J. C. Bravo Moreno. *Análisis sobre los factores administrativos y financieros por los cuales algunas PY-MES en Colombia no logran el éxito*. Ensayo para opción de grado, Universidad Militar Nueva Granada, 2013. Disponible en: <https://repository.umng.edu.co>

- [7] L. A. Cifuentes Idárraga. *Factores determinantes en la sostenibilidad financiera de la PYME ‘Flor de Loto Accesorios’ en Medellín, Antioquia*. Trabajo de grado, Tecnológico de Antioquia, 2024. Disponible en: <https://dspace.tdea.edu.co/bitstreams/1f6d1e45-b57d-4e2d-b9c4-e9c530d74dbf/download>
- [8] P. A. Rodríguez Lesmes. *La economía de los microestablecimientos en Colombia*. Documento de Trabajo, Alianza EFI – Colombia Científica, Serie WP1-2020-016, noviembre de 2020.